

DEV'IMMEDIAT - Projet 4 - Aout 2026

Collecte, préparation et anonymisation des données du CRM

Mettre le CRM en conformité avec le RGPD tout en conservant des données exploitables

Antony Labandibar - Business Intelligence Analyst



Contexte & objectif de la mission



Contexte :

À la suite d'une sanction de la CNIL, Dev'Immediat doit revoir la façon dont les données personnelles sont collectées, conservées et utilisées dans son CRM. L'entreprise doit donc corriger certaines pratiques et mettre en place des règles plus claires pour respecter le RGPD.

Constat :

Le CRM contient 10 302 lignes et 28 colonnes, avec certaines informations sensibles, très précises ou peu utiles pour un devis automobile : groupe sanguin, numéro de sécurité sociale, adresse ou employeur exact. Leur présence augmente les risques pour les clients en cas de fuite ou d'accès non autorisé.

Objectif :

La mission consiste à extraire les dossiers complets de 2022, à conserver uniquement les données nécessaires, puis à les nettoyer et les anonymiser dans Power Query. Le résultat attendu est un fichier CSV utilisable par l'équipe commerciale, mais sans identifiants directs ni tarifs exacts.

Cinq recommandations pour mettre le CRM en conformité

Minimiser la collecte

MINIMISER

Conserver seulement les informations utiles pour réaliser les devis et gérer les contrats. Les données sans utilité claire, comme le groupe sanguin, le numéro de sécurité sociale ou l'employeur exact, doivent être supprimées.

Informar les clients

INFORMER

Expliquer quelles données sont collectées, pourquoi elles sont utilisées, qui peut y accéder et pendant combien de temps. Les clients doivent pouvoir demander l'accès, la correction ou la suppression de leurs données.

Encadrer les données sensibles

ENCADRER

Ne collecter une donnée sensible que lorsqu'une justification précise existe. Son accès doit être limité et son niveau de protection renforcé.

Définir une durée de conservation

CONSERVER

Prévoir une durée adaptée pour chaque catégorie de données. Une fois cette durée dépassée, les informations doivent être supprimées, anonymisées ou archivées de manière sécurisée.

Limitar et controller les accès au CRM

SÉCURISER

Donner à chaque utilisateur uniquement les droits nécessaires à son travail. Les comptes, les consultations et les modifications doivent être contrôlés régulièrement.

Extraction SQL des dossiers complets de 2022



Base de données

CRM.sqlite

Une seule table : base_client



Données disponibles

10 302 lignes

28 colonnes



Demande réalisée en 2022

1 344 dossiers



Dossiers complets conservés

1 158 lignes

18 colonnes sélectionnées

Requête

Historique

```
1 SELECT
2   date_demande AS "Date de la demande",
3   etat_dossier AS "État du dossier",
4   sexe,
5   date_naissance,
6   id_client,
7   enfant_conduite_accompagne,
8   nombre_enfants,
9   revenus,
10  valeur_residence_prin,
11  formation,
12  usage_vehicule,
13  type_vehicule,
14  est_rouge,
15  points_perdus,
16  age_vehicule,
17  type_conduite,
18  formule,
19  tarif_devis
20 FROM base_client
21 WHERE date_demande LIKE '2022%'
22    AND etat_dossier = 'complet';
```

Requête utilisée pour sélectionner les demandes de 2022 dont le dossier est complet

Conditions appliquées

- ✓ date_demande LIKE '2022%'
- ✓ etat_dossier = 'complet'


L'extraction limite dès le départ les données aux dossiers et aux colonnes nécessaires pour la mission

Contrôle initial de la qualité des données

1

Revenus manquants


68 valeurs manquantes
Environ 6% des dossiers ne contiennent aucun revenue renseigné



2

Valeurs de residence manquantes


63 valeurs manquantes
Certaines residences ont également une valeur égale à zero, à vérifier



3

Agés de véhicule manquants

72 valeurs manquantes
Les valeurs ont été laissées vide faute d'information fiable



4

Date de naissance incohérentes


Années 2006 et plus notamment
Ces dates semblent incompatibles avec le profil d'un conducteur principal

29/11/2009
02/07/1974
10/08/2020
30/08/1953
14/03/1952
14/01/1957
04/07/1941

5

Identifiants clients répétés

19 clients apparaissent deux fois
Cela peut correspondre à plusieurs demandes réalisées par un même client



6

Valeurs et libellée inhabituels

z_SUV, z_High School, <High School
Aucune valeur n'a été corrigée au hasard lorsqu'aucune source fiable ne permettait de connaître la bonne information

<High School
<High School
<High School
Bachelors
z_High School
Masters

Aucune valeur n'a été corrigée au hasard lorsqu'aucune source fiable ne permettait de connaître la bonne information.

Minimisation et suppression des données

Conserver uniquement les informations nécessaires à la mission

Identifiants directs supprimés

Les informations permettant de retrouver directement un client n'ont pas été conservées dans l'extraction

- ✕ nom
- ✕ email
- ✕ adresse
- ✕ num_ss
- ✕ id_site_web

Données sensibles retirées

Les données sensibles ou sans utilité claire pour un devis automobile ont été supprimées

- ✕ groupe_sanguin
- ✕ id_assurance_sante

Données trop précises ou non nécessaires

Certaines informations pouvaient faciliter l'identification d'une personne lorsqu'elles étaient croisées avec d'autres données

- ✕ metier
- ✕ employeur
- ✕ lat
- ✕ lon

Transformation des informations sur les enfants

 nombre_enfants

Valeur exacte →

presence_enfant
Oui / Non

 enfant_conduite_accompagne

Valeur numérique →

présence
Oui / Non

Le nombre exact n'était pas nécessaire
Une information Oui/Non réduit la précision tout en restant exploitable




Regroupement et anonymization des données

01

Données regroupées

Les valeurs exactes sont regroupées en catégories significatives




Ex : 18 - 24 25 - 34
35 - 44 45 - 54
55 - 64 65+

02

Valeurs moins précises

Les montants et scores sont convertis en tranches



Ex : <100k € - 100 - 200k €
200 - 300k € - >300k €

03

Identifiant anonymisé

L'identifiant client est remplacé par un index anonyme



Index unique de 1 à 1158
Aucune table de correspondance transmise

OBJECTIF



Conserver les données utiles, mais réduire leur précision pour limiter le risque d'identification

Les transformations ont été réalisées dans Power Query et sont visibles dans les étapes appliquées

Les valeurs exactes d'origine sont ensuite supprimées.

Protection des données commerciales et finalisation

Dernières adaptations avant l'export du fichier final

1. Tarifs regroupés en tranches



Les montants exacts de tarif_devis ont été supprimés afin de ne pas transmettre les informations commerciales détaillées

250 à
399,99 €

400 à
599,99 €

600 à
799,99 €

800 à
1 000 €

2. Heure précise supprimée



La date était enregistrée avec l'heure exacte de la demande, cette précision n'était pas nécessaire pour l'analyse

25/02/2022 16:13:38



25/02/2022

3. Colonne devenue inutile



Après le filtrage SQL, toutes les lignes avaient déjà la valeur complet dans etat_dossier, cette colonne a donc été supprimée

etat_dossier : complet



supprimée

4. Valeurs manquantes conservées



age_vehicule contenait 72 valeurs manquantes. Aucune valeur fiable ne permettait de les compléter

72 valeurs manquantes



laissées vides

A ce stade, le fichier est prêt à être exporté en format CSV UTF-8

Résultat final de l'extraction anonymisée

Un fichier conforme, sécurisé et exploitable pour l'équipe commerciale.



1 158
demandes
conservées

Filtres 2022 + dossier complet



17
colonnes
finales

Données utiles uniquement



1 158
identifiants anonymes
uniques

ID CRM remplacé



0
erreur
technique

Transformations validées



Protection des données

- ✓ Aucun identifiant direct transmis
- ✓ Aucun tarif exact conservé (tranches tarifaires)
- ✓ Identifiant CRM remplacé par un index anonyme
- ✓ Fichier final en CSV UTF-8



Points restant à vérifier

- Valeurs manquantes dans certaines colonnes
- Dates de naissance incohérentes dans la source
- Libellés commençant par "z_" à clarifier
- Certaines incohérences à vérifier dans le CRM



Objectif atteint : réduire le risque d'identifier les clients tout en conservant un fichier exploitable par l'équipe commerciale.



Merci pour votre attention. Je suis disponible pour répondre à vos questions.