

Rapport de collecte, de préparation et d'anonymisation des données du CRM

Projet : Collectez des données en respectant les normes RGPD

Entreprise : Dev'Immediat

Auteur : Antony Labandibar

Livrable 3 – Rapport de traitement des données

Version : 1.0

Date : août 2026



1. Introduction et cadre de la mission

À la suite d'une sanction de la CNIL, Dev'Immediat doit revoir la façon dont les données personnelles sont collectées et utilisées dans son CRM. En analysant la base de données, j'ai constaté que certaines informations étaient très précises, sensibles ou ne semblaient pas vraiment utiles pour réaliser un devis automobile. C'est notamment le cas du groupe sanguin, qui est une donnée de santé, mais aussi du numéro de sécurité sociale, de l'adresse ou encore de l'employeur exact.

L'objectif de la mission est de transmettre à l'équipe commerciale les demandes d'assurance réalisées en 2022 dont le dossier est complet. La base [CRM.sqlite](#) contient une table appelée [base_client](#), composée de 10 302 lignes et de 28 colonnes. Une première requête a permis d'identifier 1 344 demandes réalisées en 2022. Après avoir ajouté la condition sur l'état du dossier, 1 158 dossiers complets ont été conservés.

Il fallait ensuite sélectionner uniquement les données réellement nécessaires et préparer le fichier afin de limiter les risques d'identifier les clients. Certaines colonnes ont donc été supprimées, tandis que d'autres ont été transformées en catégories plus larges. Par exemple, les revenus exacts ont été remplacés par des tranches et le nombre d'enfants par une information indiquant simplement leur présence ou non.

L'extraction a été réalisée dans [SQLiteStudio](#), puis les données ont été importées dans [Power Query](#). Cet outil a permis de vérifier la qualité des données, de réaliser les transformations et d'enregistrer automatiquement chaque étape, sans modifier le fichier brut d'origine.

Le résultat attendu est un fichier CSV contenant les 1 158 demandes, nettoyées et anonymisées, tout en restant utilisables par l'équipe commerciale. Le but est donc de conserver les informations utiles, mais de supprimer ou de réduire la précision des informations qui pourraient présenter un risque pour les clients.

2. Préconisations RGPD et responsabilités

L'analyse du CRM a permis d'identifier plusieurs règles à mettre en place afin de mieux protéger les données personnelles des clients et de respecter le RGPD sur le long terme.

1. Collecter uniquement les données nécessaires

Dev'Immediat doit conserver seulement les informations réellement utiles pour réaliser les devis et gérer les contrats. Les données sans rapport évident avec cette finalité, comme le groupe sanguin, le numéro de sécurité sociale ou l'employeur exact, doivent être supprimées si leur présence ne peut pas être justifiée.

2. Informer les clients et respecter leurs droits

Les clients doivent savoir quelles données sont collectées, pourquoi elles sont utilisées, qui peut y accéder et pendant combien de temps elles seront conservées. Ils doivent également pouvoir exercer leurs droits d'accès, de rectification, de suppression ou d'opposition.

3. Encadrer les données sensibles

Les données sensibles nécessitent une protection particulière et ne doivent pas être collectées sans justification légale précise. Dans le CRM, la présence du groupe sanguin doit notamment être remise en question, car cette information ne semble pas utile pour un devis automobile.

4. Limiter la durée de conservation

Une durée de conservation doit être définie pour chaque catégorie de données. Une fois leur utilité terminée, les données doivent être supprimées, anonymisées ou archivées de façon sécurisée.

5. Limiter et sécuriser les accès au CRM

Les utilisateurs ne doivent accéder qu'aux données nécessaires à leur travail. Les droits de consultation et de modification doivent dépendre du rôle de chacun, avec des comptes personnels sécurisés et régulièrement contrôlés..

Interlocuteurs concernés

La directrice valide les décisions et les moyens à mettre en place. Le DPO ou référent RGPD vérifie la conformité des mesures proposées et peut gérer les échanges avec la CNIL. Le responsable informatique ou de la sécurité contrôle les accès, les sauvegardes et la protection technique du CRM. Enfin, le responsable CRM ou l'équipe commerciale précise quelles données sont réellement nécessaires pour leur activité.

Limites de Power Query

Power Query permet de nettoyer, transformer et anonymiser l'extraction. En revanche, il ne peut pas informer les clients, gérer leurs demandes d'accès ou de suppression, définir les durées de conservation dans le CRM, attribuer les droits aux employés ou sécuriser les comptes utilisateurs. Ces actions nécessitent des décisions de la direction et l'intervention du DPO, du responsable informatique et du responsable CRM.


3. Collecte et extraction des données avec SQL

La collecte des données a été réalisée à partir du fichier `CRM.sqlite` dans SQLiteStudio. La base contient une seule table nommée `base_client`, composée de 10 302 lignes et de 28 colonnes. Avant de réaliser l'extraction finale, j'ai observé la structure de la table et vérifié les différentes valeurs présentes dans la colonne `etat_dossier`.

Une première requête a permis d'identifier 1 344 demandes réalisées en 2022. J'ai ensuite ajouté une condition pour conserver uniquement les dossiers dont l'état était `complet`. Le résultat final contient 1 158 demandes, ce qui correspond au nombre attendu pour la mission.

3.1 Requête SQL finale et export des données

Après avoir contrôlé les valeurs présentes dans la base, j'ai créé une requête SQL afin de conserver uniquement les demandes réalisées en 2022 dont le dossier était complet. J'ai également sélectionné seulement les colonnes qui pouvaient être utiles pour les traitements suivants dans Power Query.



The screenshot displays the Power Query Editor interface. The top pane, titled 'Requête', contains a SQL query. The bottom pane, titled 'Table', shows a preview of the data with a status bar indicating 'Nombre de lignes chargées : 1158'.

Requête

```
1 SELECT
2   date_demande AS "Date de la demande",
3   etat_dossier AS "État du dossier",
4   sexe,
5   date_naissance,
6   id_client,
7   enfant_conduite_accompagne,
8   nombre_enfants,
9   revenus,
10  valeur_residence_prin,
11  formation,
12  usage_vehicule,
13  type_vehicule,
14  est_rouge,
15  points_perdus,
16  age_vehicule,
17  type_conduite,
18  formule,
19  tarif_devis
20 FROM base_client
21 WHERE date_demande LIKE '2022%'
22        AND etat_dossier = 'complet';
```

Table

Formulaire

Nombre de lignes chargées : 1158

Aperçu des 1 158 lignes extraites masqué pour la publication
(données clients du CRM)


La condition `date_demande LIKE '2022%'` permet de conserver les demandes réalisées en 2022, car les dates sont enregistrées sous la forme 2022-02-25 16:13:38. La condition `etat_dossier = 'complet'` retire ensuite les dossiers incomplets. La requête retourne ainsi 1 158 lignes et 18 colonnes.

Le résultat a été exporté depuis SQLiteStudio au format CSV, avec un encodage UTF-8, un séparateur point-virgule et les noms des colonnes. Il a ensuite été importé dans Excel en choisissant **Transformer les données** afin de poursuivre le traitement dans Power Query.

4. Contrôle initial de la qualité des données

Problème constaté	Quantité ou observation
Revenus manquants	68 valeurs
Valeurs de résidence manquantes	63 valeurs
Âges du véhicule manquants	72 valeurs
Identifiants clients répétés	19 clients apparaissent deux fois
Dates de naissance incohérentes	Notamment 2017 et 2021
Valeur de résidence égale à zéro	Valeur à vérifier
Contradiction sur les enfants	Absence d'enfant mais conduite accompagnée indiquée
Libellées inhabituels	z_SUV, z_High School, z_Highly Rural/Rural

Le profilage des données a été réalisé sur les 1 158 dossiers afin de repérer les valeurs manquantes, les erreurs et les valeurs inhabituelles. Lorsque la bonne valeur n'était pas connue, je n'ai pas corrigé les données au hasard. Elles ont donc été conservées, classées dans une catégorie particulière ou signalées afin d'être vérifiées par le responsable CRM.



Profilage des colonnes réalisé dans Power Query pour identifier les valeurs manquantes et inhabituelles.

5. Préparation et anonymisation dans Power Query

5.1 Suppression et minimisation des données

Avant l'importation dans Power Query, j'ai limité la requête SQL aux 18 colonnes qui pouvaient être utiles pour l'analyse et les transformations. Les informations directement identifiantes, sensibles ou sans utilité évidente pour l'équipe commerciale n'ont donc pas été conservées dans l'extraction.

Type de données retirées	Colonnes concernées
Identifiants directs	Nom, email, adresse, num_ss, id_site_web
Données sensibles	groupe_sanguin, id_assurance_sante
Données trop précises ou non nécessaires	Metier, employeur, lat, lon

Ces colonnes ont été retirées afin de limiter les risques d'identifier les clients et de respecter le principe de minimisation. Par exemple, le groupe sanguin est une donnée de santé qui ne semble pas nécessaire pour établir un devis automobile. L'employeur, le métier et les coordonnées géographiques pourraient également faciliter l'identification d'une personne lorsqu'ils sont croisés avec d'autres informations.

Transformation des informations sur les enfants

Colonne d'origine	Nouvelle colonne
nombre_enfants	presence_enfant : Oui ou Non
enfant_conduite_accompagne	presence_enfant_conduite_accompagne : Oui ou Non

Le nombre exact d'enfants n'était pas nécessaire pour l'analyse. Les valeurs ont donc été transformées en une information indiquant seulement leur présence ou non. Une valeur égale à zéro devient « Non », tandis qu'une valeur supérieure à zéro devient « Oui ». Cette transformation réduit la précision des données tout en conservant une information exploitable.

Ajouter une colonne conditionnelle

Ajoutez une colonne conditionnelle calculée en fonction des autres colonnes ou valeurs.

Nouveau nom de colonne

Personnalisé

	Nom de la colonne	Opérateur	Valeur ①		Sortie ①
Si	nombre_enfants	est supérieur à	0	Alors	Oui
Autre...	nombre_enfants	égal à	0	Alors	Non

Ajouter une clause

Autre ①

ABC 123

OK

Annuler

Transformation du nombre exact d'enfants en une information Oui/Non dans Power Query.

5.2 Regroupement des données en catégories

Certaines informations étaient utiles pour l'analyse, mais elles étaient trop précises pour être conservées telles quelles. Elles ont donc été remplacées par des catégories plus larges. Cette méthode permet de réduire les risques d'identifier une personne tout en gardant des données exploitables par l'équipe commerciale.

Donnée d'origine	Donnée conservée
date_naissance	tranche_age
revenus	tranche_revenus
valeur_residence_prin	tranche_valeur_residence
points_perdus	tranche_points_perdus

Les valeurs manquantes des revenus et de la résidence ont été classées comme « Non renseigné ». Les valeurs de résidence égales à zéro ont été séparées dans la catégorie « Valeur égale à 0 / à vérifier », car leur signification n'était pas précisée et elles ne devaient pas être confondues avec une valeur manquante.

Ajouter une colonne conditionnelle

Ajoutez une colonne conditionnelle calculée en fonction des autres colonnes ou valeurs.

Nouveau nom de colonne

valeur_residence_prin1

	Nom de la colonne	Opérateur	Valeur ①		Sortie ①
Si	valeur_residence_...	égal à	0	Alors	Valeur égale à 0 / à vérifier
Autre...	valeur_residence_...	est inférieur ou é...	100000	Alors	1 à 100 000 €
Autre...	valeur_residence_...	est inférieur ou é...	200000	Alors	100 001 à 200 000 €
Autre...	valeur_residence_...	est inférieur ou é...	300000	Alors	200 001 à 300 000 €
Autre...	valeur_residence_...	est inférieur ou é...	500000	Alors	300 001 à 500 000 €
Autre...	valeur_residence_...	est supérieur à	500000	Alors	Plus de 500 000 €

Regroupement de la valeur de la résidence principale en différentes tranches dans Power Query.

5.3 Anonymisation et protection des données

Plusieurs traitements supplémentaires ont été réalisés afin de protéger l'identité des clients et les informations commerciales présentes dans l'extraction. Ils concernent principalement l'identifiant client, le tarif du devis et la précision de la date de la demande.

Identifiant du client

La colonne `id_client` correspondait à l'identifiant interne utilisé dans le CRM. Une personne disposant d'un accès au CRM pouvait donc utiliser cette valeur pour retrouver directement la fiche du client. Cet identifiant a été supprimé et remplacé par `id_demande_anonyme`, un index unique allant de 1 à 1 158 et propre au fichier transmis. Aucune table de correspondance avec les identifiants d'origine n'est incluse dans le CSV.

Protection des tarifs

La colonne `tarif_devis` contenait le montant exact proposé à chaque client. Afin de protéger ces informations commerciales, les tarifs ont été remplacés par quatre tranches : de 250 à 399,99 €, de 400 à 599,99 €, de 600 à 799,99 € et de 800 à 1 000 €. La colonne contenant le tarif exact a ensuite été supprimée.

Date de la demande

La date de la demande contenait également l'heure précise. Cette heure n'étant pas nécessaire pour l'analyse, elle a été supprimée. Seule la date a été conservée afin de permettre une analyse des demandes au cours de l'année 2022.

Colonnes et valeurs conservées

La colonne `etat_dossier` a été supprimée, car toutes les lignes conservées avaient déjà la valeur complet. La colonne `age_vehicule` a été conservée, mais ses 72 valeurs manquantes ont été laissées vides afin de ne pas inventer de données.

Nouveau nom de colonne

	Nom de la colonne	Opérateur	Valeur ①		Sortie ①
Si	tarif_devis	est inférieur ou é...	ABC 123 399,99	Alors	ABC 123 250 à 399,99 €
Autre...	tarif_devis	est inférieur ou é...	ABC 123 599,99	Alors	ABC 123 400 à 599,99 €
Autre...	tarif_devis	est inférieur ou é...	ABC 123 799,99	Alors	ABC 123 600 à 799,99 € ...

Autre ①
 800 à 1 000 €

Remplacement des tarifs exacts par quatre tranches tarifaires dans Power Query

6. Résultats finaux, limites et conclusion

Contrôle final	Résultat
Nombre de lignes	1158
Nombre de colonnes	17
Identifiants anonymes	1158 valeurs uniques
Erreurs techniques	0
Données directement identifiantes	Aucune
Tarifs exacts	Supprimés
Format final	CSV UTF-8

Après les traitements, le fichier final contient toujours les 1 158 demandes sélectionnées et 17 colonnes utiles pour l'analyse. Les informations qui permettaient de retrouver directement les clients, comme le nom, l'adresse, l'email, le numéro de sécurité sociale ou l'identifiant du CRM, ne sont plus présentes. Les tarifs exacts ont également été supprimés et remplacés par des tranches.

Limites et points restant à vérifier

Certaines anomalies de la base d'origine n'ont pas pu être corrigées, car je ne connaissais pas la bonne valeur. C'est notamment le cas des 72 âges de véhicule manquants, de certaines dates de naissance incohérentes, des libellés commençant par z_ et des contradictions concernant les enfants. Ces éléments devront être vérifiés par le responsable CRM.

L'index anonyme permet de différencier chaque demande, mais il ne permet plus de savoir si plusieurs demandes viennent du même client. Cette information a été retirée afin de mieux protéger les clients.

Conclusion

Le traitement réalisé a permis de réduire les risques d'identifier les clients tout en conservant un fichier utilisable par l'équipe commerciale. Les données inutiles ou sensibles ont été supprimées, les informations trop précises ont été regroupées en catégories et les tarifs confidentiels ont été protégés.

Cependant, cette extraction ne suffit pas à elle seule pour respecter le RGPD sur le long terme. Dev'Immediat doit également contrôler les accès au CRM, définir combien de temps les données sont conservées, sécuriser les comptes et informer les clients. La direction, le DPO, le responsable informatique et le responsable CRM devront donc continuer ce travail.